

**DYLAN DE MORAES RODRIGUES**

**PROMPT ARENA: Avaliação Paralela de Inteligências Artificiais**

Blumenau

Junho/2026

**Resumo**

O presente trabalho descreve o desenvolvimento da plataforma "Prompt Arena", uma aplicação web projetada para a avaliação paralela e comparativa de inteligências artificiais generativas. O objetivo central consiste em oferecer uma interface centralizada na qual usuários avançados possam disparar uma mesma consulta para múltiplos provedores (Gemini, ChatGPT, Claude, Grok e DeepSeek), permitindo a análise das respostas e a identificação de vieses ou disparidades entre os modelos. A metodologia adotada fundamenta-se na programação agêntica (agentic coding) e no Spec-Driven Development (SDD), utilizando o Claude Code, da Anthropic, e o GitHub Spec Kit como principais ferramentas de apoio ao processo. Como resultado, apresenta-se um protótipo funcional, executado em ambiente local, que integra diferentes LLMs em uma única interface, com potencial para otimizar o fluxo de trabalho do usuário final e aumentar a assertividade das consultas. Conclui-se que a centralização das respostas em uma única tela constitui uma ferramenta de apoio à comparação humana, facilitando ao próprio usuário a percepção de disparidades e a escolha da ferramenta mais adequada a cada contexto de uso.

**Palavras-chave:** inteligência artificial; avaliação de modelos; prompt arena

## **1. INTRODUÇÃO**

O recente lançamento de IAs generativas a nível comercial introduziu uma nova onda de avanços tecnológicos e adaptação a um universo de trabalho imerso no amplo uso de ferramentas de inteligência artificial generativa, baseadas em grandes modelos de linguagem (LLMs), modelos de fundação treinados em larga escala sobre vastos volumes de dados e adaptáveis a uma ampla variedade de tarefas (BOMMASANI et al., 2021). Segundo Saldanha (2025), adentramos a uma quinta revolução industrial, onde o humano colabora com a máquina de maneiras jamais antes vistas.

Neste contexto, surgem inúmeros provedores de IA no mercado, prometendo respostas cada vez mais assertivas e confiáveis, dominando uma ampla gama de assuntos. Diante de tais provedores e distintas ferramentas, passa a fazer parte da

realidade do consumidor final efetuar comparações entre diferentes LLMs de modo a descobrir qual modelo alcança o resultado mais apropriado e satisfatório. A avaliação comparativa de modelos de linguagem constitui, inclusive, um campo ativo de pesquisa, dada a multiplicidade de critérios: precisão, robustez e vieses, entre outros, envolvidos nessa análise (LIANG et al., 2023).

Diante deste cenário de análise e comparação de diferentes ferramentas de IA, propõe-se, como objetivo geral, o desenvolvimento de uma plataforma de avaliação paralela de inteligências artificiais que permita, de maneira centralizada e simplificada, efetuar a mesma consulta a diferentes agentes de IA e analisar as respostas obtidas por cada um para fins de comparação.

Como objetivos específicos, destacam-se: (a) elaborar um protótipo de interface amigável e intuitivo; (b) desenvolver um motor de backend responsável por rotear uma única solicitação a distintos LLMs de forma paralela; (c) implementar testes funcionais e automatizados; e (d) disponibilizar um protótipo funcional da aplicação web, executável em ambiente local.

O desenvolvimento deste projeto justifica-se por entregar um produto que agrega valor a usuários avançados de distintos modelos de inteligência artificial, permitindo a identificação de diferenças nos níveis de resposta e de vieses entre os resultados apresentados por cada provedor, vieses estes que podem refletir aqueles presentes nos dados utilizados no treinamento dos modelos (BENDER et al., 2021).

## **2. ESPECIFICAÇÕES INICIAIS DO SOFTWARE**

### **2.1 Escopo do Produto**

Aplicação web, executada como protótipo em ambiente local, que permite o cadastro e a execução de prompts de IA disparados em paralelo a diferentes provedores e apresentados em uma interface única e amigável, para que o usuário possa comparar as respostas obtidas.

### **2.2 Funcionalidade do Produto**

O produto deverá prover uma página inicial com autenticação mínima por usuário e senha para controle de sessão, suportando login e logout. Na página principal, o usuário poderá informar a pergunta original, selecionar os modelos de destino (suportando até quatro em paralelo) e visualizar as respostas de provedores distintos: Google Gemini (GOOGLE, 2026), OpenAI ChatGPT (OPENAI, 2026), Anthropic Claude (ANTHROPIC, 2026), X AI Grok (XAI, 2026) e DeepSeek (DEEPSEEK, 2026). Além disso, haverá uma página de histórico para revisão de análises prévias.

### **2.3 Ambiente Operacional e Tecnologias**

O desenvolvimento utiliza uma *stack* partindo de um frontend com React (META, 2026), empacotado com o Vite (VITE, 2026), seguido por Java com Spring Boot (VMWARE, 2026), integrado aos SDKs dos provedores de IA, na camada de backend. O armazenamento de dados é realizado em um banco de dados relacional leve e embarcado, o SQLite (SQLITE, 2026), adequado à execução local do protótipo. Para garantir um ambiente de execução reproduzível, a aplicação é containerizada com o Docker (DOCKER INC., 2026), permitindo executar o protótipo de forma local com um único comando.

### 3. METODOLOGIA DE DESENVOLVIMENTO DE SOFTWARE

Para a execução do projeto adotou-se uma abordagem ágil e iterativa de desenvolvimento de software, centrada na programação agêntica (agentic coding), na qual o desenvolvedor atua em colaboração com agentes de inteligência artificial para especificar, planejar, implementar e revisar o software. Essa escolha metodológica é coerente com o próprio tema deste trabalho, que investiga a colaboração entre o ser humano e os modelos de IA generativa.

A ferramenta principal do ambiente de desenvolvimento foi o Claude Code (ANTHROPIC, 2026), interface de codificação agêntica da Anthropic apoiada nos modelos de linguagem da família Claude. Por meio dela, o desenvolvedor descreve em linguagem natural a funcionalidade desejada e o agente auxilia na geração, na refatoração e na revisão do código-fonte, cabendo ao desenvolvedor as decisões de arquitetura e a validação dos resultados.

A organização do trabalho seguiu o Desenvolvimento Orientado a Especificações (Spec-Driven Development), apoiado pelo GitHub Spec Kit (GITHUB, 2026). Nessa abordagem, cada funcionalidade percorre etapas sucessivas e versionadas: a definição dos princípios do projeto (constituição), a especificação dos requisitos (*specify*), o planejamento técnico (*plan*), a decomposição em tarefas (*tasks*) e, por fim, a implementação (*implement*). Dessa forma, nenhum código é escrito antes de uma especificação revisada e aprovada, o que confere rastreabilidade e disciplina ao processo.

O versionamento do código e a documentação são mantidos em repositório público no GitHub, com o Git para controle de versões. A qualidade é acompanhada por meio de testes funcionais e automatizados, com ênfase nas integrações com os provedores de IA. A validação do protótipo é realizada de forma incremental, por meio de acesso direto e revisões internas ao final de cada ciclo de especificação e implementação.

## 4. DESENVOLVIMENTO


A arquitetura do sistema foi concebida de forma coesa e adequada a um protótipo de execução local, utilizando o ecossistema React para uma interface reativa e o Java com Spring Boot como backend responsável pela integração robusta com múltiplos LLMs.

### 4.1 Arquitetura e Modelagem

A arquitetura da plataforma Prompt Arena adota um modelo em camadas (cliente-servidor), no qual cada camada possui responsabilidade bem definida, favorecendo a escalabilidade, a manutenibilidade e o isolamento entre os provedores de inteligência artificial. A camada de apresentação é implementada como uma Single Page Application (SPA) em React, empacotada com o Vite (VITE, 2026), responsável por renderizar a interface reativa, capturar a pergunta do usuário, permitir a seleção de até quatro modelos e exibir as respostas lado a lado para comparação.

O backend, implementado em Java com Spring Boot, expõe uma API REST que centraliza o controle de sessão, recebe a pergunta do usuário e a dispara, de forma paralela e isolada, aos diferentes provedores (Google Gemini, OpenAI ChatGPT, Anthropic Claude, xAI Grok e DeepSeek) por meio de seus respectivos SDKs. O processamento concorrente das chamadas garante que a falha, a latência ou a indisponibilidade de um provedor não comprometa as respostas dos demais.

A persistência dos dados de autenticação e do histórico de análises é realizada em um banco de dados relacional embarcado, o SQLite, adequado à natureza local do protótipo. Toda a solução é containerizada com o Docker, o que permite a execução em ambiente local de forma reproduzível, com um único comando (*docker compose up*). Quanto ao fluxo de dados, a requisição parte da interface em React e é recebida pelo backend em Spring Boot, que executa as chamadas paralelas aos provedores e agrega as respostas obtidas, registrando o tempo de resposta de cada modelo, e as devolve ao frontend, persistindo simultaneamente o registro no histórico. A Figura 1 ilustra a arquitetura geral e o fluxo descrito.


**Figura 1 – Arquitetura geral da plataforma Prompt Arena**

Fonte: o autor (2026).

## 4.2 Diagramas do Sistema

Para representar o comportamento e a estrutura do sistema, foram elaborados os diagramas UML de Casos de Uso e de Classes. O diagrama de casos de uso, apresentado na Figura 2, evidencia as principais interações do usuário com a plataforma: autenticação, execução de prompts, seleção de modelos, visualização das respostas em paralelo e consulta ao histórico, além da participação dos provedores de IA como atores externos.


**Figura 2 – Diagrama de Casos de Uso**



Fonte: o autor (2026).

Já o diagrama de classes, exibido na Figura 3, representa as principais entidades do domínio e seus relacionamentos, destacando como um Usuário origina Prompts que geram Requisições disparadas a até quatro Provedores, das quais resultam as Respostas comparadas e registradas no Histórico.

**Figura 3 – Diagrama de Classes**




Fonte: o autor (2026).

### 4.3 Interfaces do Sistema

As principais interfaces previstas para a plataforma foram prototipadas de modo a validar a experiência do usuário antes da implementação. As Figuras 4 a 7 apresentam, respectivamente, os protótipos das quatro telas centrais do sistema: a tela de login, responsável pela autenticação; a tela principal, na qual o usuário digita a pergunta e seleciona os modelos; a tela de resultados, que exibe as respostas dos provedores em colunas paralelas para comparação; e a tela de histórico, que lista as análises realizadas anteriormente. Vale mencionar que as imagens a seguir representam uma estrutura base ou fundação, podendo o protótipo final ter customização de layout de botões, bordas, estilização e cores mais modernos, espelhando SPAs contemporâneas de mercado.

**Figura 4 – Tela de Login**



O protótipo da tela de login, intitulada "Prompt Arena", apresenta um formulário centralizado para o acesso à plataforma. O formulário contém o título "Acesso à Plataforma", dois campos de entrada para "usuário" e "senha", e um botão verde "Entrar".

Fonte: o autor (2026).





**Figura 7 – Tela de Histórico**

| Histórico de Análises |                                 |       |
|-----------------------|---------------------------------|-------|
| 28/06/2026            | Arquitetura para microsserviços | ver ► |
| 27/06/2026            | Comparar abordagens de cache    | ver ► |
| 25/06/2026            | Resumo de artigo científico     | ver ► |
| 24/06/2026            | Estratégias de testes E2E       | ver ► |
| 22/06/2026            | Modelagem de dados NoSQL        | ver ► |

Fonte: o autor (2026).

#### 4.4 Repositório e Código-fonte

O código-fonte do produto de software, juntamente com sua documentação técnica e Specs (especificações) geradas durante as sessões de SDD, além de todos os módulos implementados, encontra-se disponível publicamente no seguinte repositório GitHub:

<https://github.com/dylandmr/tcc-engsoft-unicesumar-dylan-rodrigues-52-2026>

## 5. CONSIDERAÇÕES FINAIS

Este trabalho apresentou a proposta e o desenvolvimento de um protótipo da plataforma Prompt Arena, voltada à comparação paralela de IAs generativas como forma de apoiar a identificação de vieses e a escolha da ferramenta mais adequada a cada contexto de uso. O protótipo desenvolvido cumpre o objetivo de simplificar o processo de análise paralela para o usuário final.

Espera-se que a integração de diferentes LLMs em uma única interface contribua para economizar tempo e ampliar a assertividade das consultas. A arquitetura proposta, baseada em camadas e na execução paralela e isolada das requisições, mostrou-se adequada, em nível de protótipo, para o cenário pretendido, ainda que sua validação em escala dependa de testes futuros.

Como trabalhos futuros, sugere-se a realização de testes de desempenho e de avaliação empírica das respostas, a implementação de métricas automatizadas de comparação e a expansão para modelos de processamento de imagem e áudio, mantendo a premissa de transparência e de apoio à comparação realizada pelo próprio usuário.

## REFERÊNCIAS

- ANTHROPIC. **Claude**. 2026. Disponível em: <https://www.anthropic.com/claude>. Acesso em: 28 jun. 2026.
- ANTHROPIC. **Claude Code: ferramenta de codificação agêntica**. 2026. Disponível em: <https://www.anthropic.com/claude-code>. Acesso em: 28 jun. 2026.
- BENDER, Emily M. et al. **On the dangers of stochastic parrots: can language models be too big?** In: ACM CONFERENCE ON FAIRNESS, ACCOUNTABILITY, AND TRANSPARENCY (FAccT '21), 2021, Virtual Event, Canada. Proceedings [...]. New York: ACM, 2021. p. 610-623. DOI: 10.1145/3442188.3445922. Disponível em: <https://dl.acm.org/doi/10.1145/3442188.3445922>. Acesso em: 28 jun. 2026.
- BOMMASANI, Rishi et al. **On the opportunities and risks of foundation models**. Stanford: Center for Research on Foundation Models (CRFM), 2021. Disponível em: <https://arxiv.org/abs/2108.07258>. Acesso em: 28 jun. 2026.
- DEEPSEEK. **DeepSeek**. 2026. Disponível em: <https://www.deepseek.com>. Acesso em: 28 jun. 2026.
- DOCKER INC. **Docker: desenvolvimento de aplicações em contêineres**. 2026. Disponível em: <https://www.docker.com>. Acesso em: 28 jun. 2026.
- GITHUB. **Spec Kit: toolkit para desenvolvimento orientado a especificações**. 2026. Disponível em: <https://github.com/github/spec-kit>. Acesso em: 28 jun. 2026.
- GOOGLE. **Gemini**. 2026. Disponível em: <https://gemini.google.com>. Acesso em: 28 jun. 2026.
- LIANG, Percy et al. **Holistic evaluation of language models**. Transactions on Machine Learning Research (TMLR), 2023. Disponível em: <https://arxiv.org/abs/2211.09110>. Acesso em: 28 jun. 2026.
- META. **React: a biblioteca para interfaces de usuário web e nativas**. 2026. Disponível em: <https://react.dev>. Acesso em: 28 jun. 2026.
- OPENAI. **ChatGPT**. 2026. Disponível em: <https://chat.openai.com>. Acesso em: 28 jun. 2026.
- SALDANHA, Thiago. O futuro já começou: como a IA está ditando a nova revolução industrial. **Startups**, 2025. Disponível em: <https://startups.com.br/artigo/o-futuro-ja-comecou-como-a-ia-esta-ditando-a-nova-revolucao-industrial>. Acesso em: 21 set. 2025.
- SQLITE. **SQLite**. 2026. Disponível em: <https://www.sqlite.org>. Acesso em: 28 jun. 2026.
- VITE. **Vite: ferramentas de frontend de nova geração**. 2026. Disponível em: <https://vite.dev>. Acesso em: 28 jun. 2026.
- VMWARE. **Spring Boot**. 2026. Disponível em: <https://spring.io/projects/spring-boot>. Acesso em: 28 jun. 2026.
- XAI. **Grok**. 2026. Disponível em: <https://x.ai>. Acesso em: 28 jun. 2026.